學號：B03701221 系級： 工管三 姓名：王逸庭

請實做以下兩種不同 feature 的模型，回答第 (1) ~ (3) 題：

1. 抽全部 9 小時內的污染源 feature 的一次項(加 bias)
2. 抽全部 9 小時內 pm2.5 的一次項當作 feature(加 bias)

備註：

a. NR 請皆設為 0，其他的數值不要做任何更動

b. 所有 advanced 的 gradient descent 技術(如: adam, adagrad 等) 都是可以用的

1. (2%)記錄誤差值 (RMSE)(根據 kaggle public+private 分數)，討論兩種 feature 的影響

RMSE(9hr):

All variable: 6.540106507

pm2.5: 6.576447856

拿全部的污染源當 feature 的表現會比只抽 PM2.5 表現較好，但差距卻不大。代表 PM2.5 和結果有高度相關，對結果有極高的預測力。但其他的變因仍有其他擁有預測力的 feature，故抽全部的誤差會比僅抽 PM2.5 的誤差來得小。

2. (1%)將 feature 從抽前 9 小時改成抽前 5 小時，討論其變化

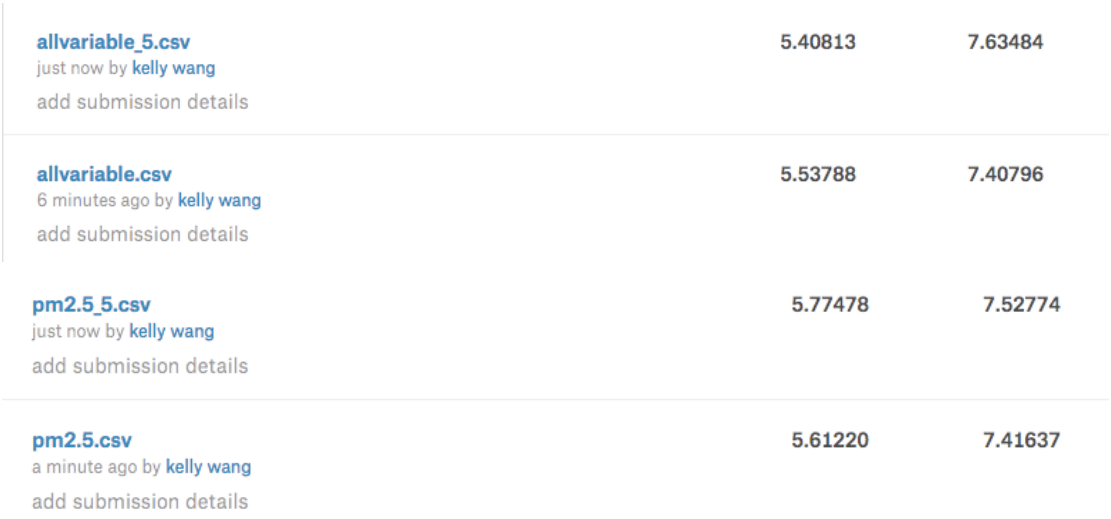

	RMSE(9hr)	RMSE(5hr)
All variable	6.540106507	6.615839022
PM2.5	6.576447856	6.708761195

從上述表格，我們取 9 小時來做訓練的效果比 5 小時好，這代表多的 4 個小時的 feature 仍有對結果有貢獻度；但至多也只有減少 0.3 的誤差，這代表主要預測的貢獻度仍集中後面的 5 個小時。

3. (1%)Regularization on all the weight with λ=0.1、0.01、0.001、0.0001，並作圖

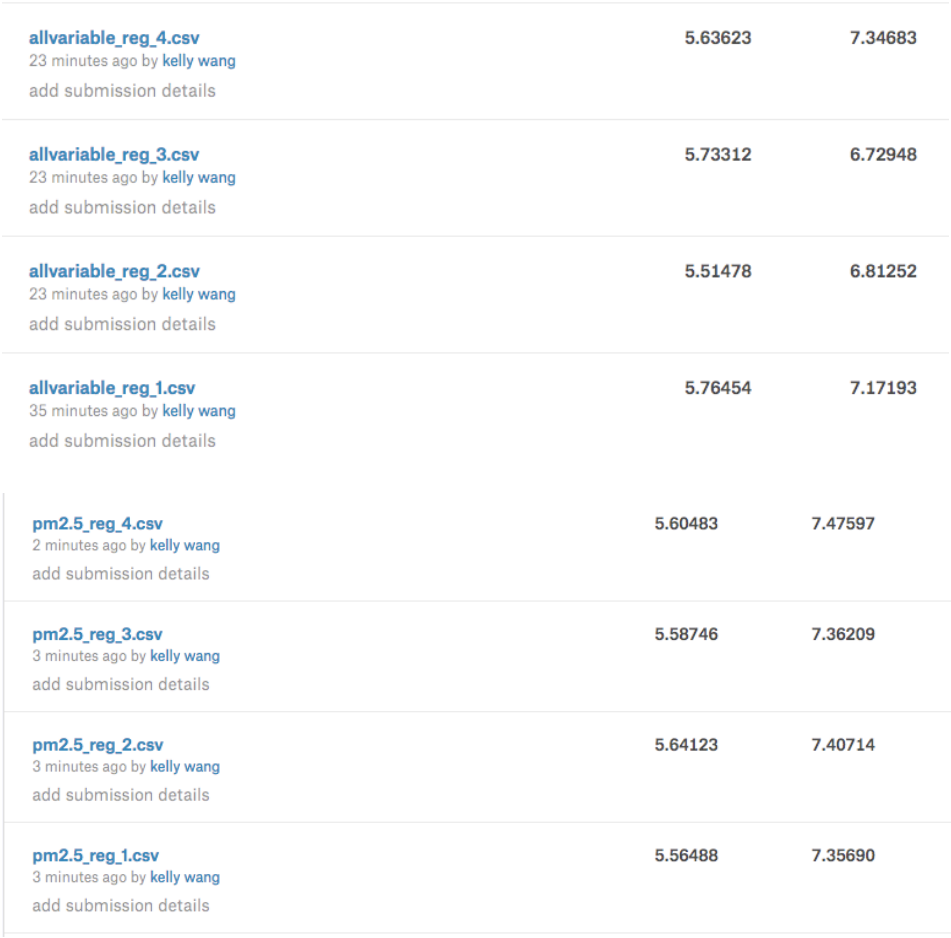

λ	All Variable	PM2.5
0.1	6.547633147	6.522724393
0.01	6.197710351	6.583661553
0.001	6.251182528	6.535291823
0.0001	6.547633147	6.606975358

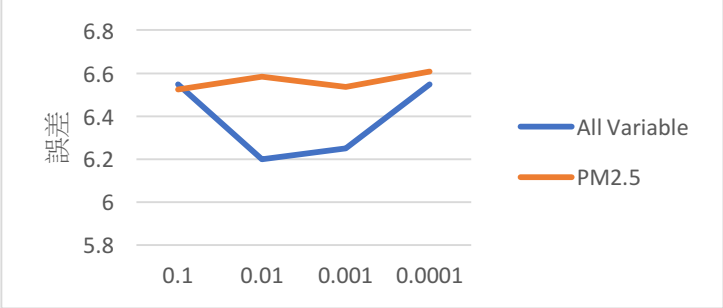

從上圖可以發現 Regularization 對於變數較多影響較多，同時λ太高或太小都無法優化此模型。

4. (1%)在線性回歸問題中，假設有 N 筆訓練資料，每筆訓練資料的特徵 (feature) 為一向量 x^n，其標註(label)為一存量 y^n，模型參數為一向量 w (此處忽略偏權值 b)，則線性回歸的損失函數(loss function)為 n=1Nyn-xnw2 。若將所有訓練資料的特徵值以矩陣 $X = [x^1\ x^2 \dots x^N]^T$ 表示，所有訓練資料的標註以向量 $y = [y^1\ y^2 \dots y^N]^T$ 表示，請問如何以 X 和 y 表示可以最小化損失函數的向量 w ？請寫下算式並選出正確答案。(其中 X^TX 為 invertible)

a. $(X^TX)X^Ty$

b. $(X^TX)^0X^Ty$

c. $(X^TX)^{-1}X^Ty$

d. $(X^TX)^{-2}X^Ty$

Ans: C

E = $||\mathbf{y} - \mathrm{X}\mathbf{w}||^2$

E: error vector

$$\sum_{n=1}^{N} (y^n - x^n \cdot w)^2$$

E = $||\mathbf{y} - \mathrm{X}\mathbf{w}||^2$

$=\varepsilon^T\varepsilon$

$=(\mathrm{y} - \mathrm{X}\mathrm{w})^T(y - Xw)$

為求最小值，此發生於微分為 0 的地方

$$\frac{\partial}{\partial \mathrm{x}}\varepsilon^T\varepsilon = 0$$

$$\frac{\partial}{\partial \mathrm{x}}(\mathrm{y} - \mathrm{X}\mathrm{w})^T(y - Xw) = 0$$

$$-2X^T(y - Xw) = 0$$

$$\mathrm{X}^T y = (X^T X)w$$

$$\mathrm{w} = (X^T X)^{-1}X^T y$$